

**ENGENHARIA ELÉTRICA – TURMA 3108**

**INTELIGÊNCIA ARTIFICIAL**

**MÉTODOS INTELIGENTES PARA DIAGNÓSTICO DE FALTAS  
EM LINHAS DE TRANSMISSÃO**

**JASON LUIZ ROMILTON COUTO**

**JUAN MIGUEL A. OLIVEIRA**

**LEONARDO NETO DE LIZ**

**VINICIUS NETO LUÍS**

**LAGES, SC**

**2020**

## **PANORAMA GERAL DOS SISTEMAS ELÉTRICOS DE POTÊNCIA**

Em sistemas elétricos de potência um grande número de mensagens e alarmes é transmitido ao centro de controle após a ocorrência de distúrbios. Tais distúrbios são provocados por diferentes tipos de faltas, podendo ocorrer em qualquer parte do sistema.

Os equipamentos de proteção são responsáveis por detectar a ocorrência de um defeito e agir apropriadamente de modo a isolar somente a parte defeituosa do sistema (seletividade). Para que o restabelecimento do sistema ocorra o mais rapidamente possível, de modo a evitar danos aos consumidores e à empresa fornecedora, é essencial que a estimativa dos eventos que produziram uma determinada sequência de alarmes ocorra de forma rápida, precisa e segura (Coutto Filho *et al.*, 1999).

## **DIAGNÓSTICO DE FALTAS EM SISTEMAS DE DISTRIBUIÇÃO**

Os sistemas de transmissão, constituídos por linhas de transmissão e subestações de alta e extra alta tensão, são normalmente gerenciados pelos sistemas SCADA e/ou EMS. A monitoração em tempo real desses sistemas viabiliza a implementação de ferramentas computacionais para diagnosticar faltas. A maioria dos artigos publicados nesta área utiliza informações sobre os estados de relés e disjuntores (Rodrigo *et al.*, 1996). Os sistemas SCADA (*Supervisory Control and Data Acquisition*) e/ou EMS (*Energy Managment Systems*) são as principais fontes de informações disponíveis aos operadores do centro de controle, as quais possibilitam um diagnóstico *on-line*, antes da etapa de restauração do sistema. Tipicamente, estes sistemas são compostos por computadores para processamento dos dados, unidades terminais remotas (UTR) espalhadas geograficamente para coleta e envio dos dados das subestações e usinas, sistemas de comunicação, e interfaces homem-máquina

Por outro lado, os sistemas de distribuição não são tão bem monitorados. Em muitos sistemas de distribuição existentes, não há a disponibilidade de registradores de sequência de eventos e tomadas de tempos precisas sobre a operação de relés e disjuntores (Teo & Gooi, 1998). A monitoração destes sistemas geralmente se restringe a relés e disjuntores até a saída de baixa tensão das subestações.

Devido à falta de informações, a tarefa de diagnóstico em sistemas de distribuição operando em 23 kV ou menos é bastante diferente daquela em tensões mais altas. Geralmente, os operadores tomam consciência da ocorrência da falta ao receberem reclamações, via telefone, dos consumidores. Tal fato implica em uma grande demanda de tempo por parte do operador para tomar conhecimento e identificar a causa dos desligamentos em situações de emergência.

Na maioria dos sistemas de distribuição são utilizados métodos manuais para determinar a causa dos desligamentos. É bastante comum o envio de uma equipe ao campo para realizar inspeções visuais nos alimentadores, sendo a comunicação entre

o operador e a turma de campo realizada por meio de rádios. A implementação do sistema SCADA e a automação dos sistemas de distribuição possibilitariam o uso de programas computacionais para apoiar os operadores na tarefa de determinar a seção defeituosa que deu origem aos desligamentos (Rodrigo *et al.*, 1996).

## **MACHINE LEARNING**

A expressão machine learning ou aprendizado de máquina pode, a princípio, soar estranha. No entanto esses sistemas podem ajudar na resolução de diversas questões, tais como: tomada de decisão em ambientes com múltiplas informações incertas e imprecisas, mobilidade urbana e segurança pública; extração de conhecimento de múltiplas bases de dados em benefício da sociedade ou até mesmo a criação de sistemas inteligentes para manutenção em ambientes industriais de alto risco.

Algoritmos inteligentes já estão inseridos nas nossas atividades diárias e nem percebemos. Quando escolhemos um filme no Netflix ou encomendamos um livro numa loja virtual, por trás dessas escolhas há a influência de algoritmos de recomendação. Também são baseadas nesta tecnologia as sugestões de rotas por aplicativos de trânsito, precificação de uma corrida no Uber, aprovações ou negações de créditos no comércio, preços dinâmicos para passagens aéreas e até as rotineiras buscas que fazemos no Google.

Uma pesquisa iniciada na UFF em 2009, contribuirá para o desenvolvimento num futuro próximo de computadores capazes de pensar e aprender a resolver os mais diversos problemas da sociedade a partir da experiência e informações recebidas. Com isso, a própria máquina passará a tomar decisões racionais com base no que já aprendeu na interação com o ambiente, analogamente ao processo decisório dos seres humanos.

O principal projeto do grupo foi executado junto a três empresas de transmissão de energia com recursos do programa de Pesquisa, Desenvolvimento e Inovação da Agência Nacional de Energia Elétrica (Aneel) chamado de Sistema Inteligente para Diagnóstico de Falhas em Linhas de Transmissão (SIDLT). Esse projeto de pesquisa e desenvolvimento (P&D), realizado em parceria com a Jordão Engenharia e financiado com recursos do programa de P&D ANEEL pelas concessionárias Cachoeira Paulista Transmissora de Energia, Linhas de Xingu Transmissora de Energia e Linhas de Macapá Transmissora de Energia, teve por objetivo o desenvolvimento de um sistema inteligente para diagnóstico de falhas em linhas de transmissão.

Este sistema computacional, baseado nos chamados modelos neurais autônomos, foi implementado em ambiente web sendo composto de três módulos: detecção, classificação e localização da falta.

## **SISTEMA INTELIGENTE PARA DIAGNÓSTICO DE FALTAS EM LINHAS DE TRANSMISSÃO (SIDLT)**

O projeto propõe o desenvolvimento de um ambiente computacional integrado para a gestão técnica de empreendimentos de transmissão, com foco na análise e diagnóstico de perturbações em linhas de transmissão. Utilizando técnicas de inteligência computacional e reconhecimento de padrões, o sistema subsidia o processo de tomada de decisão nos centros de operação da concessionária, por meio da geração de relatórios com a detecção do instante de falta de energia, classificação do tipo de falta e ainda uma estimativa da localização do defeito na linha de transmissão em análise. Além disso, é capaz de reduzir o tempo de restauração da função em virtude da identificação e localização de uma determinada falha, permitindo direcionar as equipes de campo de forma mais adequada para o restabelecimento do sistema.

Para representação dos diferentes tipos de defeitos em estudo, devem ser estabelecidos os parâmetros que devem ser variados juntamente com seus possíveis valores para que assim seja estabelecida uma árvore de falhas fidedigna. Quando ocorre um curto circuito em uma linha de transmissão, por exemplo, são gerados nela surtos de tensão e corrente que se propagam em ambas as direções rumo aos seus terminais de acordo com a velocidade de propagação do surto da linha. Tais surtos se comportam como ondas viajantes e sofrem reflexões e refrações devido às descontinuidades do sistema, esse processo de reflexões sucessivas se repete até que seja alcançada a condição de regime permanente associado ao distúrbio. O desempenho da ferramenta em termos de diagnóstico está diretamente relacionado com a capacidade de modelagem dos componentes da rede e dos diferentes cenários de faltas, realizada através da inserção correta dos dados no sistema de simulação que se deseja avaliar. Neste sentido, apresentou-se um razoável espectro de valores para os parâmetros que efetivamente influenciam o comportamento das oscilografias de tensão e corrente na ocorrência de diferentes tipos de curto-circuito, conforme listados a seguir:

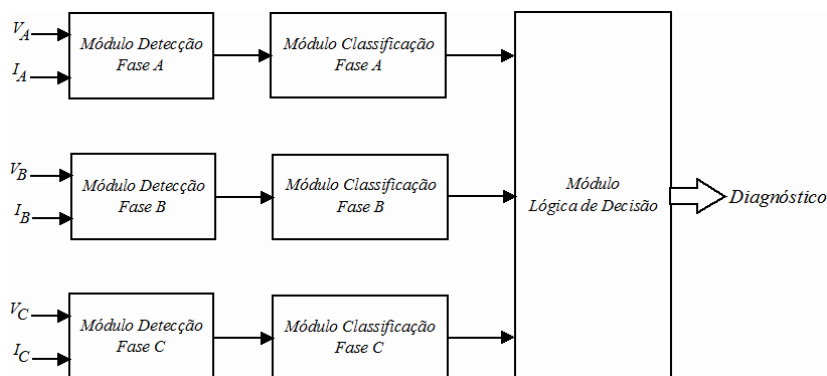
- Tipo e resistência de falta;
- Localização da falta;
- Ângulo de incidência da falta (fase da tensão no momento da falta).

Para sistematização das simulações foram criados casos separados para cada uma das linhas de transmissão. Nestes casos, incluiu-se a modelagem dos disjuntores de cada seção e circuito da linha para possibilitar realizar a eliminação do defeito, uma nomenclatura uniforme para permitir a aplicação de curto-circuito em qualquer ponto de cada circuito da linha e um único conjunto de quatro chaves em série com resistências, que permitirá a modelagem de cada tipo de defeito e o nome do nó terminal deste conjunto permitirá especificar a real localização do ponto de falta.

Para sistematização das simulações foram criados casos separados para cada uma das linhas de transmissão. Nestes casos, incluiu-se a modelagem dos disjuntores de cada seção e circuito da linha para possibilitar realizar a eliminação do defeito, uma nomenclatura uniforme para permitir a aplicação de curto-circuito em qualquer ponto de cada circuito da linha e um único conjunto de quatro chaves em série com resistências, que permitirá a modelagem de cada tipo de defeito e o nome do nó terminal deste conjunto permitirá especificar a real localização do ponto de falta.

A lista de nós é configurável no programa protótipo, podendo ser alterada. O programa manipula o arquivo texto (arquivo ATP) substituindo os campos correspondentes para os diversos valores desejado de cada uma das simulações, O arquivo ATP é gerado pelo ATPDraw a partir de seu arquivo binário que contém as informações do circuito elétrico modelado, incluindo o seu desenho, parâmetros e topologia (arquivo ACP). A aplicação de uma falta genérica em um ponto genérico em um tempo genérico é definida por quatro resistências e quatro chaves. A escolha dos parâmetros destes elementos que irão definir o tipo e resistência de falta, o ângulo de incidência, pela variação do tempo de aplicação da falta e a localização.

Pelos resultados apresentados, concluiu-se que há uma perspectiva para que as simulações utilizadas no treinamento do sistema inteligente produzam resultados adequados. Imagina-se que na próxima fase de implantação do Sistema Inteligente será possível não só identificar a localização de defeitos internos, como identificação do circuito, se é um defeito externo e o tipo de defeito.



*Figura de uma estrutura do sistema para detecção e classificação de faltas implementado.*

## **MÉTODOS INTELIGENTES**

Muitos métodos de diagnóstico de falhas em linhas de transmissão são baseados em cálculos determinísticos ou em modelo do sistema, o que traz algumas dificuldades para tais métodos, devido a fatores como complexidade do modelo do sistema, falta de conhecimento de seus parâmetros, grande quantidade de informações a serem processadas e incapacidade de adaptação dinâmica às variações de operação do sistema (Youssef, 2004).

Com o desenvolvimento dos algoritmos para diagnóstico de falhas baseado em análise de transitórios, verificou-se que a Transformada Wavelet permite a investigação dos sinais transitórios gerados no SEP, onde a decomposição dos sinais de falta em várias escalas da Transformada Wavelet permite que o diagnóstico seja alcançado. Apesar da Transformada Wavelet ser muito eficaz em detectar sinais transitórios gerados pelas faltas, ela pode não ser suficiente para uma caracterização completa (Chiradeja e Ngaopitakkul, 2009).

Para superar tais dificuldades, nos últimos anos têm sido propostos métodos inteligentes baseados em RNA e Lógica *Fuzzy*, e Redes *Neurofuzzy*, sendo que, as Redes *Neurofuzzy* aproveitam a capacidade de aprendizado das RNAs e a capacidade de tratamento da incerteza da Lógica *Fuzzy* na construção de métodos de diagnóstico de falhas mais eficientes.

## **REDES NEURAIIS ARTIFICIAIS**

As Redes Neurais Artificiais (RNAs) ou simplesmente Redes Neurais, representam uma tecnologia que está presente em muitas áreas, tais como neurociências, matemática, estatística, física, ciência da computação e engenharia. As RNAs são aplicadas em diversos campos, como por exemplo: modelagem, análise de séries temporais, reconhecimento de padrões, processamento de sinais e controle de processos. Isto se deve a uma importante propriedade das RNAs: a capacidade de aprender a partir de dados de entrada com ou sem professor (Haykin, 1999).


## **EXEMPLOS EMPREGANDO REDES NEURAIIS ARTIFICIAIS**

Normalmente, o uso das RNAs para diagnóstico de faltas em linhas de transmissão é tratado como um problema de reconhecimento de padrões, ou seja, a rede é treinada para reconhecer sinais senoidais puros como um indicador de condição normal do sistema e 35 mudanças de amplitude, fase, ou presença de transitórios como indicador de ocorrência da falta. Sinais de tensão ou corrente podem ser utilizados para detecção da falta, mas geralmente o sinal de corrente é mais

sensível à ocorrência da falta do que o sinal de tensão (Vásquez; Altuve; Chacón, 1996).

No trabalho de Vásquez, Altuve e Chacón (1996) é apresentado um método para detecção de faltas em linhas de transmissão baseado em redes neurais. Nesse artigo é proposto o uso de uma RNA tipo *Multilayer Perceptron* (MLP), com uma camada de entrada de 5 ou 10 nós fonte (depende do tamanho da janela de dados empregada), uma camada oculta com 20 neurônios e uma camada de saída de apenas um neurônio. Os padrões de entrada da rede consistem em sinais de corrente extraídos da linha, que passam por um filtro *anti-aliasing* e depois são amostrados a uma frequência de 960Hz. Diferentes redes foram treinadas e avaliadas quanto a sua capacidade de identificar transições entre os estados de pré-falta e falta da linha. Com rede treinada, a mesma classifica os padrões de entrada em duas classes, ou seja, a saída igual a 1 para indicar a linha com falta e saída igual a 0 para indicar a linha sem falta.

A figura abaixo apresenta a estrutura do método de detecção de faltas baseado em RNA proposto.



*Estrutura do método de detecção de faltas baseado em RNA (Vásquez, Altuve, e Chacón, 1996).*

## LÓGICA FUZZY

A lógica *fuzzy* (ou lógica nebulosa) é a lógica baseada na teoria dos conjuntos *fuzzy* (ou conjuntos nebulosos) introduzida por Lotfi A. Zadeh em um artigo publicado em 1965. Lógica *fuzzy* e conjuntos *fuzzy* se tornaram uma das áreas consolidadas nas tecnologias de processamento de informações. Estudos recentes estão espalhados por várias áreas, tais como controle de processos, reconhecimento de padrões, sistemas especialistas, visão computacional e vida artificial. Um grande número de aplicações para o mundo real foram desenvolvidas e vão desde aplicações domésticas até aplicações industriais, envolvendo 39 apenas lógica *fuzzy* ou lógica *fuzzy* em conjunto com outras abordagens, como redes neurais (Pedrycz e Gomide, 1998).



A abordagem utilizada no diagnóstico de falhas em linhas de transmissão com uso da lógica *fuzzy* é geralmente o Sistema de Inferência *Fuzzy* (*Fuzzy Inference Systems - FIS*) padrão, constituído basicamente de três componentes: *fuzzy*ificação, máquina de inferência e *defuzzy*ificação. Nesse sistema, as entradas são valores numéricos (amostras de tensão e/ou corrente) que são convertidos em variáveis *fuzzy*. As entradas *fuzzy*ificadas são aplicadas na máquina de inferência *fuzzy*, que produz a saída na forma *fuzzy* de acordo com a base de regras *fuzzy*. A regra *fuzzy* é selecionada conforme o tipo da falta. A saída da máquina de inferência é *defuzzy*ificada para se obter a saída numérica (informação sobre a falta) (Mahanty; Gupta, 2006). O trabalho de Das e Reddy (2005) apresenta um método para classificação de faltas em linhas de transmissão baseado em lógica *fuzzy*. Nesse artigo é proposto um algoritmo de classificação que emprega a diferença angular entre as componentes de sequência das correntes de falta, bem como as magnitudes relativas das mesmas, como informações sobre a falta.




Diagrama em bloco do FIS empregado para classificação de faltas proposto por Das e Reddy (2005).

Nos trabalhos citados que empregam lógica *fuzzy* para diagnóstico de faltas em linhas de transmissão, os resultados obtidos demonstram que os métodos propostos alcançam índices de desempenho igual a outros métodos de diagnóstico de faltas. Porém, os autores destacam que os métodos propostos possuem vantagens em relação à outros métodos de diagnóstico de faltas, que são vantagens inerentes à lógica *fuzzy*, como a capacidade de lidar com a incerteza que surge devido à variação dos parâmetros da linha de transmissão, simplificação do método devido à menor complexidade para se implementar um sistema *fuzzy* e, conseqüentemente, redução do custo computacional.



Tanto as RNAs quanto os sistemas baseados em lógica *fuzzy* apresentam alguns pontos fracos. RNAs tem o problema da representação implícita do conhecimento, enquanto sistemas *fuzzy* são subjetivos e heurísticos. A determinação das regras *fuzzy*, fatores de escala para entrada e saída e escolha das funções de pertinência dependem do método da tentativa e erro, o que faz com que o projeto de sistemas *fuzzy* seja uma tarefa demorada. Estas desvantagens das RNAs e sistemas *fuzzy* são superadas pela integração da capacidade de aprendizado das RNAs como a robustez dos sistemas *fuzzy*, de forma que os conceitos da lógica *fuzzy* são embutidos na estrutura da rede, resultando num ambiente natural que combina a informação numérica na forma de pares entrada/saída com a informação linguística na forma de regras SE-ENTÃO de maneira uniforme (Dash, Pradhan e Panda, 2000). De forma geral, todas as combinação de RNAs e sistemas *fuzzy* são denominadas de sistemas *neurofuzzy*.

Muitas arquiteturas de redes *neurofuzzy* têm sido propostas na literatura. Uma das mais populares é a Rede Adaptativa Baseada em Sistema de Inferência Fuzzy (*Adaptive Network based Fuzzy Inference System – ANFIS*), proposta por R. R. Jang (Jang, Sun e Mizutani, 1997). Essa rede consiste em um sistema *neurofuzzy* híbrido que é funcionalmente equivalente a um sistema *fuzzy*. As características apresentadas pelas redes *neurofuzzy* como a *ANFIS* permitem que essas substituam RNAs e sistema *fuzzy* em diversas aplicações e com vantagens. A capacidade de adaptabilidade da *ANFIS*, sua não-linearidade e a representação do conhecimento de forma estruturada, são as principais vantagens desse sistema em relação à abordagens clássicas (Jang, Sun e Mizutani, 1997). Em contrapartida, as redes *neurofuzzy* apresentam uma limitação com relação ao número de entradas, pois, devido à chamada explosão combinatória do número de regras (o número de regras é igual o número de funções de pertinência elevado ao número de entradas). Com um número de entradas grande, o número de regras torna a rede impraticável.

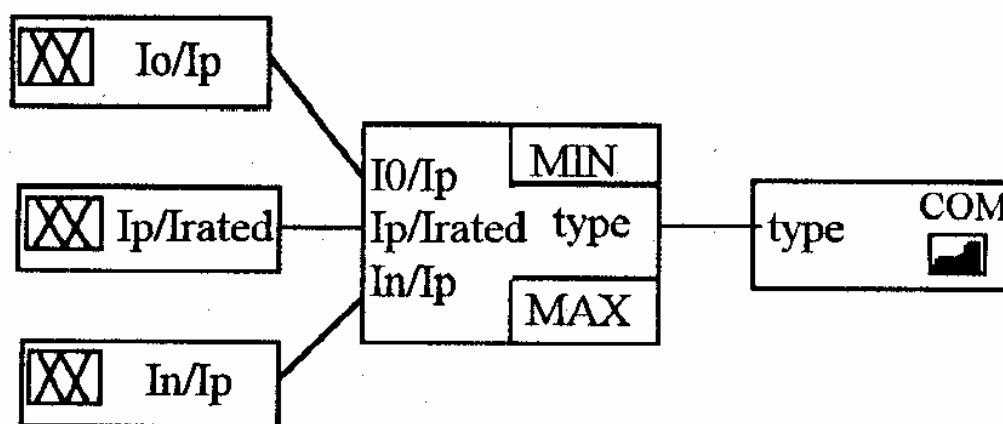
### **EXEMPLOS EMPREGANDO REDES NEUROFUZZY**

Assim como no caso das RNAs, as redes *neurofuzzy* são utilizadas no diagnóstico de falhas em linhas de transmissão sob a ótica da classificação de padrões, ou seja, a rede é treinada para reconhecer sinais de tensão e/ou corrente da linha como padrões normais (sem perturbações) ou padrões de falta (com perturbações). As diferenças entre as abordagens utilizando RNAs e redes *neurofuzzy* estão nas próprias características das redes, que determinarão o desempenho das mesmas na tarefa de diagnóstico de falhas.

No trabalho de Wang e Keerthipala (1998) é apresentado um método para detecção e classificação de faltas em linhas de transmissão baseado em redes *neurofuzzy*. Nesse artigo é proposto o uso de uma típica rede *neurofuzzy* de três camadas: uma camada de fuzzyficação, uma camada de inferência e uma camada de defuzzyficação. Como padrões de entrada da 44 rede, os autores utilizaram variáveis que representam as relações entre componentes de sequência e a taxa de variação das correntes extraídas da linha, sendo essas variáveis definidas como:

- \*  $I_0/I_p$  = relação entre as componentes de sequência zero e sequência positiva;
- \*  $I_p/I_{rated}$  = relação entre a componente de sequência positiva e taxa de variação;
- \*  $I_n/I_p$  = relação entre as componentes de sequência negativa e sequência positiva;

A rede *neurofuzzy* é treinada a partir de padrões de entrada, de forma a atualizar a estrutura e definir os parâmetros da rede, utilizando o algoritmo de treinamento *backpropagation*. A saída defuzzyficada da rede indica o tipo da falta, entre os tipos: falta entre fases (LL), falta entre uma fase e terra (LG), falta entre duas fases e terra (LLG) e faltas trifásica e terra (TLG). A figura abaixo apresenta a estrutura da rede *neurofuzzy* para detecção e classificação de faltas proposto.



Estrutura da rede neurofuzzy para detecção e classificação de faltas proposta por Wang e Keerthipala (1998).

## REFERENCIAS BIBLIOGRÁFICAS

PESSANO, Jorge. **Inteligência Artificial: UFF cria soluções inovadoras para a sociedade.** 2017. Disponível em: <http://www.uff.br/?q=noticias/19-09-2017/inteligencia-artificial-uff-cria-solucoes-inovadoras-para-sociedade>. Acesso em: 03 out. 2020.

FERREIRA, Vitor Hugo *et al.* **SISTEMA INTELIGENTE PARA DIAGNÓSTICO DE FALTAS EM LINHAS DE TRANSMISSÃO.** 2017. Disponível em: [https://www.scielo.br/scielo.php?script=sci\\_arttext&pid=S0103-17592004000200010&lng=pt&tlng=pt](https://www.scielo.br/scielo.php?script=sci_arttext&pid=S0103-17592004000200010&lng=pt&tlng=pt). Acesso em: 03 out. 2020.

Coutto Filho, M. B. do; Rodrigues, M. A. P.; Souza, J. C. S. *et al.*; 1999. Localização de defeitos em sistemas de energia elétrica utilizando sistemas inteligentes. In: *XV SNPTEE, Seminário Nacional de Produção e Transmissão de Energia Elétrica* (Outubro 1999: Paraná, Brasil). p.1-7.

RODRIGO, P. D.; Pahwa, A.; Boyer, J. E.; 1996. Location of outages in distribution systems based on statistical hypotheses testing. *IEEE Transactions on Power Delivery*, Vol. 11, No. 1 (Jan.), p. 546-551.

Teo, C. Y. & Gooi, H. B.; 1998. Artificial intelligence in diagnosis and supply restoration for a distribution network. *IEE Proc.-Gener. Transm. Distrib.*, Vol. 145, No. 4 (July), p. 444-450.

INÁCIO, Maurílio José. **DETECÇÃO E CLASSIFICAÇÃO DE FALTAS EM LINHAS DE TRANSMISSÃO UTILIZANDO TRANSFORMADA WAVELET E REDE LÓGICA NEUROFUZZY COM APRENDIZADO PARTICIPATIVO.** 2010. 104 f. Dissertação (Mestrado) - Curso de Engenharia Elétrica, Universidade Federal de Minas Gerais, Belo Horizonte, 2010. Disponível em: [https://www.google.com/search?client=firefox-b-d&ei=7cl4X92sOI295OUPgcutyAs&q=FALTAS+EM+LINHAS+DE+TRANSMISS%C3%83O++fuzzy&oq=FALTAS+EM+LINHAS+DE+TRANSMISS%C3%83O++fuzzy&gs\\_lcp=CgZwc3ktYWIQAzoECAAQRzoECCEQCIDmF1i-O2DfSmgAcAJ4AIABpgGIAd0NkgEEMC4xM5gBAKABAaoBB2d3cy13aXrlAQjAAQE&sclient=psy-ab&ved=0ahUKEwid18q5jZnsAhWNHrkGHYFIC7kQ4dUDCAw&uact=5](https://www.google.com/search?client=firefox-b-d&ei=7cl4X92sOI295OUPgcutyAs&q=FALTAS+EM+LINHAS+DE+TRANSMISS%C3%83O++fuzzy&oq=FALTAS+EM+LINHAS+DE+TRANSMISS%C3%83O++fuzzy&gs_lcp=CgZwc3ktYWIQAzoECAAQRzoECCEQCIDmF1i-O2DfSmgAcAJ4AIABpgGIAd0NkgEEMC4xM5gBAKABAaoBB2d3cy13aXrlAQjAAQE&sclient=psy-ab&ved=0ahUKEwid18q5jZnsAhWNHrkGHYFIC7kQ4dUDCAw&uact=5). Acesso em: 03 out. 2020.